

Plateforme Agent IA RH

Plateforme de recrutement multi-agents, de la publication d'offre à l'onboarding.
Spécification d'ingénierie pour l'équipe de stagiaires.

VERSION	1.0 — Juillet 2026
AUDIENCE	Équipe de stagiaires ingénieurs Welyne (3–4 développeurs)
POLITIQUE STACK	Gratuit & open-source d'abord (Groq, LangGraph, Postgres). Outils payants autorisés si clairement meilleurs.
CALENDRIER	12 semaines, 4 phases, démo toutes les 2–3 semaines
STATUT	Prêt pour implémentation

Sommaire

§	Section	Contenu
1	Objectif, périmètre & KPIs	Ce qu'on construit, définition du « fini », métriques cibles
2	Architecture système	Services, modèle d'orchestration, machine à états des candidatures
3	Stack technologique	Choix gratuits/OSS d'abord : Groq, LangGraph, Postgres, et les replis
4	Modèle de données	Tables coeur et les deux schémas JSON dont tout dépend
5	Services partagés	Passerelle LLM, messagerie, registre de prompts, harnais d'évaluation
6	Spécifications des sous-agents	A0–A9 : mission, pipeline, outils, critères d'acceptation par agent
7	Sécurité, confidentialité & IA responsable	PII, consentement, contrôle des biais, règles human-in-the-loop
8	Plan de livraison	4 phases sur 12 semaines, répartition d'équipe, méthodes de travail
9	Annexes	Schémas JSON, squelette de prompt de scoring, API, variables d'env

1. Objectif, périmètre & KPIs

Welyne One est une plateforme multi-agents : des agents IA spécialisés, chacun expert de sa tâche, coordonnés par un orchestrateur intelligent. Ce document spécifie le produit **Agent IA RH** — un cycle de recrutement automatisé couvrant les six étapes de la méthode Welyne : **(1) publication d'offre automatisée** → **(2) analyse de CV** → **(3) pré-qualification conversationnelle** → **(4) scoring & matching** → **(5) planification d'entretiens** → **(6) onboarding intelligent**, plus les capacités périphériques : sourcing, contenus de formation et reporting.

La cible de build est un **MVP de qualité production** : un recruteur téléverse (ou reçoit par email) un lot de CV face à une fiche de poste et obtient, en quelques minutes, une shortlist classée avec des scores justifiés, des communications candidats automatiques, une pré-qualification par chat, des créneaux d'entretien et un parcours d'onboarding — le tout supervisé depuis un tableau de bord, avec un humain qui valide chaque décision sensible.

1.1 KPIs cibles (critères d'acceptation de la démo finale)


Métrique	Référence (manuel)	Cible avec la plateforme
Délai jusqu'à la shortlist classée (50 CV)	3–5 jours	moins de 2 heures
CV traités par jour	~30	500+
Heures recruteur par campagne	40–60 h	8–12 h (–80 %)
Première réponse au candidat	3–5 jours	moins de 24 h (accusé instantané)
Cohérence du scoring (même CV, 3 passages)	n/a	écart-type inférieur à 5 points / 100
Taux de parsing réussi sur fichiers réels	n/a	au moins 95 % sans erreur bloquante

1.2 Hors périmètre pour le MVP

- Paie, congés et toute fonctionnalité SIRH post-onboarding.
- Scraping automatisé de profils LinkedIn (risque CGU — voir l'agent A2 pour la conception conforme).
- Rejets entièrement automatiques : **chaque rejet exige un clic humain** (voir §7).
- Fine-tuning de modèles. Uniquement des modèles open-weight hébergés + prompt engineering + retrieval.

2. Architecture système

Un monorepo, cinq services runtime, une seule base de données. Les agents ne sont **pas** des microservices séparés : ce sont des graphes LangGraph exécutés dans le worker. Le système reste ainsi déployable par les stagiaires avec un seul *docker compose up*.



2.1 Modèle d'orchestration

A0 est un **graphe superviseur LangGraph** persisté avec le checkpointeur Postgres. Chaque sous-agent est un noeud (ou sous-graphe) avec ses outils et ses prompts. L'orchestrateur possède la **machine à états des candidatures** — la source de vérité unique sur l'avancement d'un candidat :

```
RECEIVED -> PARSED -> SCORED -> { SHORTLISTED | POOL | DECLINE_PENDING }
SHORTLISTED -> PRESCREENING -> PRESCREENED -> INTERVIEW_SCHEDULED -> INTERVIEWED
INTERVIEWED -> { OFFER -> HIRED -> ONBOARDING } | DECLINE_PENDING
DECLINE_PENDING -(validation recruteur)-> DECLINED (email envoyé seulement après validation)
```

- Chaque transition est écrite dans *audit_log* avec l'acteur (agent ou humain), l'horodatage, le modèle + la version du prompt.
- Les échecs sont rejoués avec backoff exponentiel (3 tentatives) puis la candidature est parquée dans une file *NEEDS_ATTENTION* visible sur le dashboard.
- Les portes human-in-the-loop utilisent *interrupt()* de LangGraph : le graphe se met en pause, le dashboard affiche une carte de validation, le clic du recruteur relance le graphe.

3. Stack technologique — gratuit & open-source d'abord

Règle d'équipe : **par défaut, l'option gratuite/OSS ci-dessous ; ne passer à une alternative payante que si vous démontrez que l'option gratuite bloque un KPI**, et consignez la décision dans le DECISIONS.md du repo.

Couche	Choix	Pourquoi / notes
Inférence LLM	API Groq (tier gratuit, sans carte)	Vitesse LPU, SDK compatible OpenAI. Raisonnement/scoring : <i>llama-3.3-70b-versatile</i> ou <i>openai/gpt-oss-120b</i> . Extraction en volume : <i>llama-3.1-8b-instant</i> (14 400 req/jour gratuites). STT si besoin : <i>whisper-large-v3-turbo</i> . Vérifiez console.groq.com/docs/models — la liste évolue.
Repli LLM	Tier gratuit Google Gemini · Tier gratuit Mistral La Plateforme · Ollama local	Les tiers gratuits sont limités (Groq ≈ 30 req/min, 1k req/jour sur le 70B). Passez par la passerelle (\$5.1) avec repli automatique. Mistral est fort en français. Ollama (qwen3:8b / llama3.1:8b) permet le dev hors-ligne.

Couche	Choix	Pourquoi / notes
Framework agents	LangChain + LangGraph (Python)	Pattern superviseur, checkpointer Postgres pour des graphes reprenables, interrupt() pour les portes humaines, tool calling natif. Alternative si bloqués : CrewAI (prototypage plus rapide, moins de contrôle).
Sortie structurée	Schémas Pydantic v2 + mode JSON / tool calling	Tout appel LLM qui alimente la base DOIT valider un schéma Pydantic ; en cas d'échec, une tentative de réparation, puis rejet.
Embeddings	BAAI/bge-m3 via sentence-transformers	Poids ouverts, multilingue (français / anglais / arabe — les CV tunisiens mélangent les trois), 1024 dim, tourne sur CPU.
Base vectorielle	Extension pgvector	Une seule base pour tout (lignes + vecteurs). Pas de base vectorielle séparée à opérer.
Base de données	PostgreSQL 16 + SQLAlchemy 2 + Alembic	Migrations dès le premier jour.
API backend	FastAPI + Uvicorn	Async, typé, docs OpenAPI gratuites.
Jobs / file	Celery + Redis	Lots de CV et exécutions d'agents en tâches de fond ; Redis sert aussi de cache.
Parsing documents	PyMuPDF · python-docx · Docling · OCR Tesseract (fra+eng+ara)	Docling pour les mises en page complexes ; Tesseract en repli pour les CV scannés (fréquents en Tunisie).
Frontend	Next.js 15 + Tailwind + shadcn/ui + Recharts	Dashboard + portail candidat dans une seule app.
Email	SMTP (dev : mot de passe d'application Gmail) → tier gratuit Resend/Brevo	Tous les envois passent par le service de messagerie (§5.2), templétés, journalisés.
WhatsApp	Meta WhatsApp Business Cloud API (tier dev gratuit)	Le bac à sable Twilio est acceptable pour la démo.
Planification	Cal.com auto-hébergé (OSS) ou API Google Calendar	Cal.com fournit pages de réservation + webhooks clés en main.
Observabilité LLM	Langfuse auto-hébergé (OSS)	Tracez chaque appel : prompt, tokens, latence, coût. Tout bug doit lier une trace.
Auth	JWT FastAPI + bcrypt (rôles : admin / recruteur / lecteur)	Keycloak plus tard si SSO requis.
Déploiement / CI	Docker Compose · GitHub Actions (lint, tests, build)	Un VPS suffit pour le MVP.

Kit de survie tiers gratuits

Les tiers gratuits throttlent : attendez-vous à des HTTP 429. La passerelle LLM (§5.1) doit implémenter retry avec backoff, lire les en-têtes de rate-limit, mettre en file les appels non urgents (le scoring en lot peut attendre quelques minutes), et replier Groq → Gemini → Mistral → Ollama. Jamais de clé API dans le code ; .env + env.example du repo.

4. Modèle de données

Schéma relationnel coeur (simplifié — les stagiaires possèdent le jeu final de migrations). JSONB est utilisé quand la forme est produite par LLM et validée par Pydantic.

Table	Champs clés	Notes
jobs	id, title, status, job_spec JSONB, weights JSONB, created_by	job_spec = fiche de poste structurée (agent A1)
candidates	id, full_name, email, phone, links JSONB, pii_masked_key	dédoublonnage sur hash email/téléphone normalisés
applications	id, job_id, candidate_id, status, source, stage_history JSONB	status = machine à états du §2.1
documents	id, application_id, kind (cv/lettre/diplôme), storage_path, mime, ocr_used bool, raw_text	fichier original conservé immuable
candidate_profiles	application_id, profile JSONB, language, parser_version	schéma CandidateProfile (Annexe A)
scores	application_id, total, subscores JSONB, verdict, justification, evidence JSONB, model, prompt_version, run_seed	schéma ScoreCard (Annexe B) ; une ligne par passage
conversations / messages	channel (web/email/whatsapp), transcript, extracted JSONB, consent_at	pré-qualification (A5)
interviews	application_id, slot_start, slot_end, calendar_ref, status	A6
message_log	to, channel, template_id, rendered_body, status, validated_by	chaque message sortant (A7)
onboarding_tasks	application_id, task, owner, due_date, status, doc_path	checklists A8 + documents collectés
users / roles	email, password_hash, role	admin / recruteur / lecteur
prompt_versions	agent, name, version, template, created_at	registre du §5.3
audit_log	entity, entity_id, action, actor, payload JSONB, at	append-only
embeddings	owner_type, owner_id, section, vector(1024)	pgvector ; sections de fiche de poste + sections de profil

5. Services partagés de la plateforme

5.1 Passerelle LLM

Module interne léger (ou conteneur proxy LiteLLM) que chaque agent doit appeler au lieu d'attaquer les fournisseurs directement. Responsabilités : routage par profil de tâche (*extracteur* → petit modèle 8B rapide, *juge* → 70B / gpt-oss-120b, *chat* → 70B), retries + chaîne de repli, budget de rate-limit par agent, journalisation tokens & latence vers Langfuse, temperature=0 et seed fixe pour tout ce qui est scoré ou stocké.

5.2 Service de messagerie

Point de passage unique pour email et WhatsApp. Ne rend que des templates approuvés (accusé de réception, invitation pré-qualification, invitation entretien, rejet, offre, bienvenue onboarding) avec personnalisation LLM **uniquement dans des emplacements bornés du template**. Journalise chaque envoi dans *message_log*. Les templates de rejet ne peuvent partir que depuis un état DECLINE_PENDING validé.

5.3 Registre de prompts

Les prompts vivent dans */prompts/<agent>/<nom>@vN.md*, synchronisés vers la table *prompt_versions* au démarrage. Toute sortie LLM stockée porte (modèle, prompt_version). Changer un prompt = nouvelle version + run d'éval (§5.4) — jamais d'édition en place.

5.4 Harnais d'évaluation (c'est ce qui rend le projet sérieux)

- **Jeu de référence** : 30 CV réels anonymisés (PDF/DOCX/scans, mix FR/EN/AR) + 5 fiches de poste, avec classements de référence faits par un recruteur. À constituer en semaine 2 — c'est un livrable.

- **Évals parseur** : précision champ par champ du CandidateProfile vs annotations manuelles ; cible $\geq 90\%$ sur noms, dates, intitulés, compétences.
- **Évals scoring** : corrélation de rang de Spearman vs classement recruteur $\geq 0,75$; écart-type par CV sur 3 passages < 5 points ; rapport par prompt_version.
- **Sonde de biais** : re-scoring le jeu de référence avec noms/genres permutés (le pipeline masqué doit donner des scores identiques — l'affirmer par un test).
- Exécution avec pytest + une petite CLI (*make evals*) ; les résultats s'ajoutent à /evals/reports/ et sont montrés à la démo hebdo.

6. Spécifications des sous-agents

Pour chaque agent : mission, déclencheur & E/S, pipeline, outils, critères d'acceptation (CA) et livrables stagiaires (L). Les estimations supposent que les services partagés du §5 existent.

A0

Orchestrateur People AI

Graphe superviseur qui route le travail entre les agents, possède la machine à états des candidatures, impose les portes humaines, les retries et l'audit.

Déclencheur	Tout nouvel événement : candidature créée, parsing terminé, score prêt, chat fini, action recruteur.
Entrées / Sorties	Événements + état de candidature → invocation de l'agent suivant, transitions d'état, entrées d'audit.
Outils	StateGraph LangGraph + checkpointer Postgres, Celery pour l'exécution, interrupt() pour les portes humaines.

Pipeline / règles

- Implémente exactement la machine à états du §2.1 ; les transitions illégales lèvent une erreur et atterrissent dans NEEDS_ATTENTION.
- Portes sensibles (interrupt) : envoi de tout rejet ; publication externe d'une offre ; envoi d'une offre d'embauche.
- Idempotence : chaque étape est indexée par (application_id, step, attempt) pour que les retries ne dupliquent jamais un email ou un score.

Critères d'acceptation & livrables

- CA : tuer le worker au milieu d'un lot de 50 CV → redémarrer → le lot se termine sans aucun doublon (preuve par checkpointer).
- CA : il n'existe aucun chemin dans le code où un email de rejet part sans porte humaine validée (test qui l'affirme).
- L : définition du graphe, tests de la machine à états, file NEEDS_ATTENTION dans le dashboard. **Estimation : 1,5 semaine** (croît avec chaque agent ajouté).

A1

Agent Création & Publication d'offres

Transforme une fiche de poste brute ou un brief recruteur en JobSpec structuré, critères de scoring pondérés, et contenus de publication multicanaux.

Déclencheur	Le recruteur crée une offre : colle le texte, téléverse un DOCX/PDF, ou répond à un formulaire guidé de 6 questions.
Entrées / Sorties	Fiche brute → JobSpec JSON (intitulé, missions, indispensables, atouts, séniorité, langues, localisation, fourchette salariale, critères éliminatoires) + pondérations par critère + variantes par canal (post LinkedIn, texte job-board, page carrières, message WhatsApp) + lien de candidature avec UTM.

Outils	Modèle 70B avec schéma JSON ; bibliothèque de templates par canal ; éditeur dashboard pour revue humaine avant publication.
---------------	---

Pipeline

- Extraire → normaliser les compétences contre la taxonomie (démarrer avec les libellés ESCO stockés en table) → proposer des pondérations par défaut (curseurs éditables par le recruteur) → générer les variantes par canal → approbation humaine → porte de publication.
- La publication est en mode **générer-et-assister** pour le MVP : contenus + lien de tracking produits ; auto-publication seulement là où une vraie API existe (page carrières = la nôtre ; job boards = copier-coller au jour 1).

Critères d'acceptation & livrables

- CA : 10 fiches réelles désordonnées → JobSpec valide sans aucune erreur de schéma ; les éditions du recruteur sont sauvegardées comme overrides.
- CA : les critères éliminatoires sont capturés séparément (ils pilotent les filtres durs de A4).
- L : schéma JobSpec, formulaire guidé, UI d'édition des pondérations, templates par canal. **Estimation : 1 semaine.**

A2

Agent Sourcing (LinkedIn & au-delà)

Remplit le haut du funnel : canaux entrants d'abord, plus un mode « assistance LinkedIn » conforme qui démultiplie un sourceur humain au lieu de l'imiter.

Décision de conformité (à lire avant de coder)

LinkedIn n'offre aucune API officielle gratuite de recherche de profils, et le scraping automatisé / la connexion par bot violent ses CGU — comptes bannis et risque juridique pour l'entreprise (et les données de recrutement sont des données personnelles au sens de la loi tunisienne 2004-63 et du RGPD pour les candidats UE). Le MVP livre donc le **mode assistance**, pas de scraping. Les API d'enrichissement payantes pourront être évaluées plus tard comme décision business par Welyne — pas par l'équipe de stagiaires.

Déclencheur	Offre publiée (A1) ou le recruteur ouvre l'onglet « Sourcing » d'une offre.
Entrées / Sorties	JobSpec → chaînes de recherche booléennes & X-ray (site:linkedin.com/in ...), brouillons de messages d'approche personnalisés (3 tons), une zone de collage/import pour les profils exportés par le recruteur, et des candidatures taguées par source.
Outils	Modèle 70B pour la génération de requêtes & messages ; importeur CSV/URL ; API de job boards optionnelles si gratuites.

Pipeline

- Générer 5–10 chaînes de recherche par offre (intitulés, synonymes, variantes FR/EN, filtres de localisation) classées par précision attendue.
- Le recruteur lance les recherches manuellement ; colle les URLs / exports ; l'agent parse les infos publiques fournies par le candidat ou les exports PDF de profil via A3 vers le même schéma CandidateProfile.
- Brouillons d'approche personnalisés depuis le JobSpec + ce que le recruteur a collé ; l'envoi reste manuel (le recruteur copie).

Critères d'acceptation & livrables

- CA : pour 3 offres de test, les chaînes générées font remonter au moins 10 profils plausibles dans les 2 premières pages (jugement humain).
- CA : les profils importés traversent parsing + scoring exactement comme les CV reçus par email, tagués source=linkedin_assist.

- L : générateur de requêtes, générateur d'approches, importeur, flux d'analytics de sources pour A9.
Estimation : 1 semaine.

A3

Agent CV — ingestion & parsing

Transforme tout CV entrant (upload, formulaire, boîte email ; PDF/DOCX/image ; FR/EN/AR) en CandidateProfile JSON validé, avec traçabilité complète vers le texte source.

Déclencheur	Fichier téléversé sur le portail/dashboard, ou nouvel email avec pièce jointe sur la boîte recrutement (poll IMAP toutes les 2 min).
Entrées / Sorties	Fichier brut → original stocké + raw_text + CandidateProfile JSON (Annexe A) + langue + verdict de dédoublonnage.
Outils	PyMuPDF, python-docx, Docling ; Tesseract (fra+eng+ara) quand la couche texte < 200 caractères/page ; langdetect ; modèle 8B pour l'extraction avec schéma JSON ; passe de réparation 70B en cas d'échec de validation.

Pipeline

- Ingestion → détection mime → extraction texte → repli OCR → détection de langue → découpage si > 8k tokens.
- Extraction LLM vers le schéma : identité, contact, liens ; experiences[] avec dates normalisées et durées calculées ; education[] ; compétences normalisées vers la taxonomie + mentions brutes conservées ; langues ; certifications.
- Post-traitement : années d'expérience totales calculées en code (pas par le LLM) ; contrôles de cohérence des dates ; dédoublonnage par hash email/téléphone puis nom flou + date de naissance ; rattachement au candidat existant si correspondance.
- Stockage du profil avec parser_version ; émission de l'événement PARSED vers A0.

Critères d'acceptation & livrables

- CA : ≥ 95 % des fichiers du jeu de référence produisent un profil valide sans crash (scans inclus).
- CA : précision des champs ≥ 90 % sur le jeu de référence ; chaque expérience extraite garde un extrait source (page + snippet) pour les liens de preuve utilisés par A4.
- CA : débit — un lot de 50 CV entièrement parsé en moins de 15 min sous les limites du tier gratuit (file consciente des quotas).
- L : workers d'ingestion (upload + IMAP), module de parsing, logique de dédoublonnage, suite d'évals du parseur. **Estimation : 2 semaines. C'est la fondation — à construire en premier.**

A4

Agent Scoring & Matching

Score chaque candidature de 0 à 100 face au JobSpec avec sous-scores, bande de verdict et justification écrite appuyée sur des preuves — objectif, cohérent, biais contrôlés.

Déclencheur	Événement PARSED de A0.
Entrées / Sorties	CandidateProfile + JobSpec + pondérations → ScoreCard JSON (Annexe B) : sous-scores (adéquation expérience /30, compétences /30, formation /20, adéquation secteur & contexte /20 — pondérations configurables par offre), total /100, verdict, justification avec extraits de preuve cités.
Outils	Hybride : moteur de règles (filtres durs), similarité pgvector (bge-m3), juge 70B avec prompt-grille à température 0.

Pipeline — trois étages, du moins cher au plus cher

- **1. Filtres durs (code, sans LLM) :** critères éliminatoires du JobSpec (ex. langue requise, permis de travail, années min). Échec → DECLINE_PENDING avec motif, jamais envoyé automatiquement.

- **2. Rapprochement sémantique** : embed des sections de la fiche et du profil ; les similarités cosinus (compétences↔exigences, expérience↔missions) deviennent des features, et pré-classent les lots pour que le juge voie le meilleur d'abord.
- **3. Juge LLM** : profil masqué (voir ci-dessous) + JobSpec + grille → sous-scores avec une ligne de preuve par sous-score citant le CV. Bandes de verdict par défaut : ≥ 70 shortlist, 45–69 vivier, < 45 rejet-en-attente (configurable par offre).
- **Contrôle des biais** : le juge ne voit jamais nom, photo, âge, genre, adresse, nationalité, situation familiale — une fonction de masquage les retire et la suite d'évals affirme l'invariance des scores sous permutation de noms/genres.
- Cohérence : température 0, seed fixe, stockage de (modèle, prompt_version, run_seed) avec chaque ScoreCard.

Critères d'acceptation & livrables

- CA : Spearman $\geq 0,75$ vs classement recruteur sur le jeu de référence ; écart-type < 5 points sur 3 passages par CV.
- CA : chaque citation de preuve d'un sous-score existe réellement dans le raw_text (test vérificateur).
- CA : la sonde de biais passe (scores identiques sous identités permutées).
- L : moteur de règles, features d'embeddings, prompt juge v1, carte ScoreCard dans l'UI avec preuves dépliables, rapport d'éval. **Estimation : 2 semaines.**

A5

Agent de Pré-qualification conversationnelle

Mène un dialogue de screening structuré 24/7 avec les candidats shortlistés via chat web, email et WhatsApp, en FR/EN/AR, et transforme la conversation en données structurées.

Déclencheur	La candidature atteint SHORTLISTED ; A7 envoie l'invitation avec lien de chat / opt-in WhatsApp.
Entrées / Sorties	JobSpec + profil → 5–8 questions générées spécifiques au poste (disponibilité, préavis, prétentions salariales, mobilité, confirmation de 2–3 compétences clés, vérifications éliminatoires) → transcript + réponses extraites JSON fusionnées au profil + drapeaux (contradictions, signaux d'alerte, excellents signaux).
Outils	Sous-graphe de dialogue LangGraph avec état de slot-filling ; modèle chat 70B ; webhook WhatsApp Cloud API ; parsing des réponses email ; widget de chat web sur le portail.

Pipeline / règles

- Ouvre avec l'identité de l'agent + mention de consentement (« assistant IA de <entreprise> ; réponses enregistrées pour votre candidature ») — obligatoire, journalisée avec horodatage.
- Slot-filling : ne pose que les questions sans réponse, accepte le texte libre, redemande une fois en cas d'ambiguïté, ne débat jamais ; hors-script ou sujet sensible → drapeau de passage poli au recruteur.
- Timeout 48 h → une relance → marquer PRESCREEN_INCOMPLETE (le recruteur décide).
- Le résumeur produit un récap de 5 lignes + champs mis à jour ; les contradictions vs CV sont signalées, pas jugées.

Critères d'acceptation & livrables

- CA : 80 % de 20 dialogues de test scriptés (incl. FR/AR, fautes de frappe, digressions) aboutissent sans aide humaine ; tous les slots stockés.
- CA : consentement enregistré avant toute question ; conversation exportable en PDF pour le dossier.
- L : graphe de dialogue, générateur de questions, canaux WhatsApp + web (email si le temps le permet), carte récap dans le dashboard. **Estimation : 2 semaines.**

A6

Agent de Planification d'entretiens

Supprime le ping-pong d'agendas : propose des créneaux, réserve, confirme, relance, replanifie.

Déclencheur	PRESCREENED avec avis recruteur positif, ou clic recruteur « inviter à un entretien ».
Entrées / Sorties	Disponibilités recruteur (event type Cal.com ou free/busy Google) → 3 créneaux proposés au candidat → entretien réservé + invitation ICS + rappels (24 h avant, des deux côtés) + flux de replanification/annulation.
Outils	API + webhooks Cal.com auto-hébergé (préféré) ou API Google Calendar ; messagerie via A7.

Critères d'acceptation & livrables

- CA : démo de réservation de bout en bout incluant une replanification et un marquage no-show ; états synchronisés avec le pipeline.
- CA : sûr côté fuseaux horaires (TZ du candidat détectée/demandée ; stockage en UTC).
- L : module d'intégration calendrier, embed de réservation, jobs de rappel. **Estimation : 1 semaine.**

A7

Agent Communications (partagé)

Tous les messages vers les candidats : accusé de réception instantané, invitations, rejets bienveillants, offres, bienvenue onboarding — templétés, personnalisés dans des limites, entièrement journalisés.

Déclencheur	Événements de A0 (transitions d'état) ou actions explicites du recruteur.
Entrées / Sorties	Événement + contexte de candidature → message rendu depuis un template approuvé (FR/EN selon la langue du candidat) avec emplacements personnalisés par LLM (max 2 phrases, ton encadré) → envoyé via le service de messagerie, journalisé.
Outils	Bibliothèque de templates (Jinja2), modèle 8B pour la personnalisation des emplacements, service de messagerie (§5.2).

- Règle dure : **les rejets exigent un clic recruteur** (porte DECLINE_PENDING). Les accusés de réception sont le seul envoi entièrement automatique.
- Chaque message stocke template_id + corps rendu ; rate-limit par candidat (max 1 message / 4 h hors confirmations).
- CA : aucun chemin d'envoi non journalisé n'existe (test) ; L : jeu de templates ×2 langues, garde-fous de personnalisation, centre de messages dans l'UI. **Estimation : 1 semaine.**

A8

Agent Onboarding intelligent

De « embauché » à une excellente première semaine : checklist personnalisée, collecte de documents, relances, et un assistant Q&R ancré dans le manuel de l'entreprise.

Déclencheur	La candidature atteint HIRED.
Entrées / Sorties	Template de rôle + JobSpec → plan d'onboarding personnalisé (documents à collecter : CIN, RIB, diplômes, contrat signé ; comptes & équipement ; agenda semaine 1 ; réunions d'intro) → tâches suivies + portail d'upload candidat + email pack de bienvenue.
Outils	Moteur de checklist (lignes dans onboarding_tasks), portail d'upload, RAG sur le manuel : découpage → bge-m3 → pgvector → réponses 70B avec citations, repli « je ne sais pas ».

- CA : démo de bout en bout avec un manuel d'exemple — 10 questions de test répondues avec citations correctes, 0 politique hallucinée (refuse à la place).
- CA : la checklist de documents atteint 100 % avec relances ; les tâches expirées escaladent vers le responsable RH.

■ L : générateur de plan, portail, pipeline RAG + questions d'éval. **Estimation : 1,5 semaine.**

A9

Agent Reporting & Analytics

Rend visible la valeur de la plateforme : funnel, vitesse, qualité, sources, SLAs des agents et coûts en tokens.

Déclencheur	Job d'agrégation nocturne + requêtes live du dashboard.
Entrées / Sorties	Tables d'événements & d'audit → dashboard KPI : funnel reçus→parsés→scorés→shortlist→entretien→offre→embauche ; délais ; distributions de scores par offre ; efficacité des sources (incl. linkedin_assist) ; SLAs parsing/scoring ; tokens & coût estimé par embauche ; export CSV/PDF.
Outils	Vues SQL + petites tables d'agrégats, Recharts sur le dashboard, job Celery beat planifié.

■ CA : les chiffres se réconcilient avec les tables brutes (script de contrôle) ; L : dashboard 8 widgets + digest email hebdo aux admins. **Estimation : 1 semaine.**

7. Sécurité, confidentialité & IA responsable

- **Cadre légal** : les données candidats sont des données personnelles — la loi organique tunisienne 2004-63 (INPDP) s'applique ; le RGPD s'applique pour les candidats UE ; l'AI Act européen classe l'IA de recrutement comme à haut risque. Les conséquences pratiques ci-dessous sont obligatoires, pas optionnelles.
- **Consentement & transparence** : le formulaire de candidature et le chat indiquent qu'une IA assiste le processus et qu'un humain prend les décisions finales ; horodatage du consentement stocké.
- **Human-in-the-loop** : aucun rejet, aucune offre, aucune publication externe sans clic recruteur ; le journal d'audit prouve qui a décidé quoi, quand, avec quel modèle + version de prompt.
- **Minimisation & masquage** : le scoring ne voit jamais nom/photo/âge/genre/adresse ; PII masquées dans les traces Langfuse ; accès par rôle.
- **Rétention** : purge/anonymisation par défaut des candidatures 12 mois après clôture ; un endpoint de suppression efface un candidat sur demande.
- **Secrets & transport** : .env uniquement, TLS partout, mots de passe bcrypt, pas de PII dans les logs, audit hebdo des dépendances en CI.
- **Surveillance des biais** : la sonde de biais du §5.4 tourne en CI ; contrôle des distributions de scores par offre avant toute publication de shortlist.

8. Plan de livraison — 12 semaines, 4 phases

Phase	Semaines	Périmètre	Porte de démo (définition du fini)
0	1	Repo, Docker Compose (api, worker, db, redis, langfuse), CI, squelette auth, hello-world passerelle LLM sur Groq, début de collecte du jeu de référence	docker compose up → login → un appel LLM tracé visible dans Langfuse
1	2–4	Valeur cœur : A3 parsing CV + A4 scoring + liste minimale dashboard + A0 v1 + jeu de référence terminé	Démo 1 : 50 CV réels + 1 fiche de poste → shortlist classée avec scores appuyés sur preuves, export CSV/PDF ; parseur ≥ 95 %, Spearman ≥ 0,75
2	5–6	A1 création d'offre & éditeur de pondérations, A7 communications + porte HITL de rejet, vue pipeline du dashboard	Démo 2 : flux complet boîte email → parsé → scoré → accusé envoyé → le recruteur valide un rejet

Phase	Semaines	Périmètre	Porte de démon (définition du fini)
3	7–9	A5 pré-qualification (chat web d'abord, puis WhatsApp), A6 planification via Cal.com	Démon 3 : un candidat shortlisté discute, réponses stockées, réserve un entretien, reçoit des rappels
4	10–12	A2 assistance sourcing, A8 onboarding + RAG manuel, A9 reporting, durcissement, test de charge (500 CV/jour), rapport d'éval final	Finale : tous les KPIs du §1.1 démontrés en live ; rapport d'éval + runbook livrés

8.1 Répartition d'équipe suggérée (3–4 stagiaires)

Rôle	Responsable de	Premières tâches
Backend & data	FastAPI, schéma/migrations, A0, A6, déploiement	Infra phase 0, machine à états
Pipelines LLM & évals	Passerelle, A3, A4, harnais §5.4, Langfuse	Jeu de référence, parseur v1
Frontend	Dashboard, portail, widget de chat, vues A9	Pages d'auth, liste des candidatures
Intégrations (ou réparti entre les trois)	IMAP, WhatsApp, Cal.com, email, glue A1/A2/A7/A8	SMTP + templates

8.2 Méthodes de travail (non négociables)

- Trunk-based, petites PRs, revue par un autre stagiaire sous 24 h ; CI verte avant merge.
- Démon du vendredi sur données réelles chaque semaine ; chaque rapport de bug lie une trace Langfuse.
- DECISIONS.md pour chaque écart de stack ; les prompts ne changent que par nouvelle version + run d'éval.
- Définition du fini : code + test + migration + trace + ligne de doc dans le README.

9. Annexes

Annexe A — CandidateProfile (schéma JSON condensé)

```
{
  "identity": {"full_name": str, "email": str|null, "phone": str|null,
    "location": str|null, "links": [str]},
  "experiences": [{"title": str, "company": str, "start": "AAAA-MM", "end": "AAAA-MM|present",
    "duration_months": int, "description": str, "evidence_span": {"page": int, "text": str}}],
  "education": [{"degree": str, "field": str, "institution": str, "year": int|null}],
  "skills": [{"raw": str, "normalized": str|null, "level": "basic|good|expert|null"}],
  "languages": [{"lang": str, "level": str}],
  "certifications": [str], "total_experience_months": int, # calculé en code
  "detected_language": "fr|en|ar", "parser_version": str
}
```

Annexe B — ScoreCard (schéma JSON condensé)

```
{
  "subscores": {"experience_fit": 0-30, "skills_fit": 0-30,
               "education_fit": 0-20, "sector_context_fit": 0-20},
  "total": 0-100, "verdict": "SHORTLIST|POOL|DECLINE_PENDING",
  "hard_filter_failures": [str],
  "justification": str, # 4-6 phrases, professionnel, cite les preuves
  "evidence": [{"subscore": str, "quote": str, "page": int}],
  "model": str, "prompt_version": str, "run_seed": int
}
```

Annexe C — Squelette du prompt-grille de scoring (juge)

SYSTEM: Tu es un évaluateur de recrutement strict et équitable. Score UNIQUEMENT à partir du profil masqué et de la fiche de poste. Cite une preuve verbatim pour chaque sous-score. Si une information manque, score prudemment et dis-le. Sortie JSON uniquement, conforme au schéma ScoreCard. Pas de noms, pas de suppositions sur l'identité.

USER: {JobSpec JSON}
 {ponderations par critere}
 {CandidateProfile JSON masqué}
 experience_fit : pertinence+seniorite vs missions ... (grille v1 dans /prompts/a4/)

Annexe D — Surface API (v1, condensée)

POST /auth/login | GET /jobs | POST /jobs | PATCH /jobs/{id}/weights | POST /jobs/{id}/publish*
 POST /applications/upload (multipart) | GET /applications?job=&status;=&min;_score=
 GET /applications/{id} (profil+scorecard+timeline) | POST /applications/{id}/validate-decline*
 POST /applications/{id}/invite-prescreen | POST /applications/{id}/invite-interview
 POST /chat/webhook/whatsapp | POST /chat/{conv_id}/message | GET /reports/funnel?job=
 POST /candidates/{id}/erase (RGPD/2004-63) | * = porte humaine (interrupt)

Annexe E — Variables d'environnement (extrait)

```
GROQ_API_KEY= GEMINI_API_KEY= MISTRAL_API_KEY= # chaîne de repli passerelle
MODEL_JUDGE=llama-3.3-70b-versatile MODEL_EXTRACT=llama-3.1-8b-instant
DATABASE_URL=postgresql://... REDIS_URL=redis://... LANGFUSE_HOST=...
SMTP_HOST= SMTP_USER= SMTP_PASS= WHATSAPP_TOKEN= WHATSAPP_PHONE_ID=
CALCOM_URL= CALCOM_API_KEY= JWT_SECRET= PII_MASK_SALT=
```

Fin de la spécification — Welyne One · Agent IA RH · v1.0 · Juillet 2026. Questions et demandes de changement : ouvrir une issue taguée [spec] dans le repo.